

UNIVERSIDADE DE SÃO PAULO - USP
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO -
ICMC

DAVI FAGUNDES FERREIRA DA SILVA - 12544013
ANTONIO MOREIRA - 9779242
DANIEL PENNA CHAVES BERTAZZO - 10349561
FABRÍCIO NASCIMENTO DE LIMA - 15824942

SCC0633 - PROCESSAMENTO DE LINGUAGEM
NATURAL
GRAMATQUIZ

SÃO CARLOS
2025

SUMÁRIO

	Introdução	2
1	PROPOSTA	3
1.1	A Aplicação	3
1.2	Arquitetura do projeto	3
1.3	Explicação da arquitetura	4
1.3.1	Frontend	4
1.3.2	ASR-API	4
1.3.3	POS-API	5
1.4	Recursos e ferramentas utilizados	5
1.5	Cópus Escolhidos	6
1.6	Testes e Resultados	6
1.6.1	Whisper	6
1.6.2	Stanza	6
2	MODELO SIMBÓLICO	8
2.1	Dataset e pré-processamento	8
2.2	Detalhes da modelagem	8
2.2.1	Construção das Regras Simbólicas	9
2.3	Resultados	12
3	MODELO NEURAL	13
3.1	Detalhes da arquitetura	13
3.1.1	O BERT	13
3.1.2	O BERTimbau	13
3.2	O Conjunto de Dados	14
3.2.1	Pré-processamento e Treinamento	14
3.3	Resultados	15
4	APÊNDICES	16
4.1	Análise das etiquetas na abordagem simbólica	16
	REFERÊNCIAS	20

INTRODUÇÃO

Com o objetivo de facilitar e tornar mais divertido o estudo de gramática, o grupo apresenta o *GramatiQuiz*, uma solução capaz de ouvir uma sentença dita pelo aluno e propor um *quiz* para adivinhar qual a função morfofossintática das palavras contidas na sentença. A Figura 1 demonstra o funcionamento básico do projeto.




Figura 1 – Diagrama representando a interface proposta para o software. Em cima, uma frase é apresentada para o aluno; embaixo, as etiquetas morfofossintáticas de cada palavra são disponibilizadas fora de ordem. O aluno deve clicar na tag e arrastar para a palavra que acredita ser correspondente. Em seguida, haverá uma indicação de erro ou acerto.

O público alvo do *GramatiQuiz* são alunos do ensino fundamental e médio, tendo como principal objetivo fornecer uma maneira interativa e divertida de estudar gramática a nível escolar, mais especificamente a análise morfofossintática de frases. Além disso, com base nas interações dos alunos registradas no *GramatiQuiz* (tanto erros quanto acertos), é possível utilizar modelos de inteligência artificial para prever a série em que o aluno está. Dessa forma, é possível realizar uma análise do estado do ensino básico de língua portuguesa nas escolas brasileiras, e se a capacidade dos alunos de uma certa série está condizente com o esperado.

O software desenvolvido utiliza tecnologias de processamento de linguagem natural (PLN), como reconhecimento automático de fala (ASR) e análise morfofossintática (*POS tagging*) para transcrever a fala e analisar o conteúdo da mesma. Dessa forma, é possível fornecer um retorno educacional imediato, permitindo que o aluno compreenda melhor a estrutura gramatical da língua portuguesa por meio da própria fala.

1 PROPOSTA

1.1 A Aplicação

Visando a feira de ciências na USP, a aplicação tem como público-alvo os alunos do ensino fundamental e médio. Deste modo, os itens a seguir descrevem as iterações dos usuários com a plataforma:

- Após habilitar o microfone do navegador o aluno aperta o botão de gravar e diz uma sentença à sua escolha. Quando a sentença é finalizada ele deve parar a gravação;
- A sentença dita é exibida para a confirmação do aluno, caso deseje alterar algo. Em caso de aceite deverá clicar em *confirmar*;
- Por fim, uma tela será exibida para o aluno realizar o *quiz* morfológico. Ao concluir será exibida uma mensagem informando em quantas tentativas ele conseguiu.

Uma representação visual do fluxo da aplicação pode ser vista na Figura 2.

1.2 Arquitetura do projeto

A arquitetura proposta é composta por três módulos principais que serão explicadas adiante:

- *Frontend* (*Vue.js* + *Vite* + *Bulma*)
- ASR-API (Reconhecimento Automático de Fala com *Whisper* via *FastAPI*). WER score de 6.3% em português na versão *large-v2*, como consta em (RADFORD et al., 2022).
- POS-API (Análise Morfossintática com *Stanza* via *FastAPI*). Performance de 92.9% na tarefa de *Named Entity Recognition*, como consta (QI et al., 2020). Em nosso *baseline*, obtivemos uma performance quase idêntica de 92% na tarefa de etiquetagem morfossintática em português com o *corpus* Portinari-base (PARDO et al., 2021).

Cada módulo é responsável por uma etapa fundamental no processo de entrada e análise da fala.

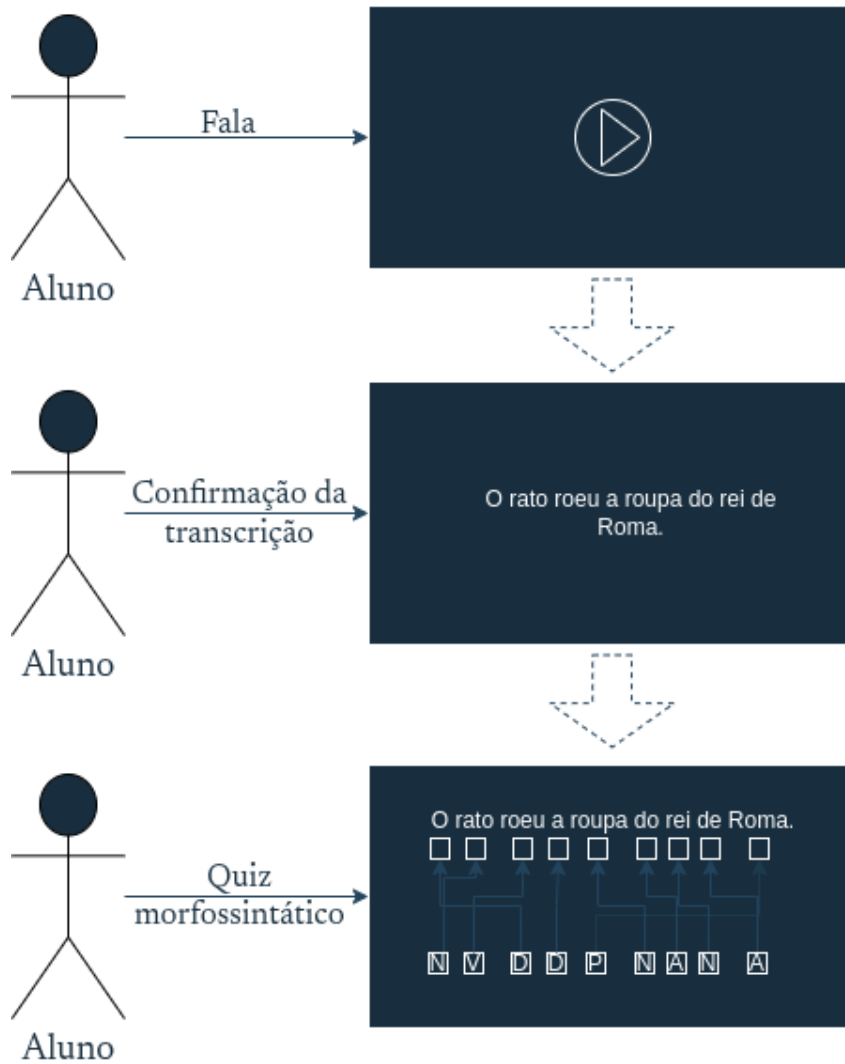


Figura 2 – Iterações do aluno com a aplicação.

1.3 Explicação da arquitetura

1.3.1 Frontend

Desenvolvido com *Vue.js*, utilizando o *Vite* como ambiente de desenvolvimento e o *Bulma* como *framework CSS*, o *frontend* permite a captação de áudio diretamente do navegador e exibe os resultados da transcrição e análise morfofossintática. É também no *frontend* onde é feito o *quiz* para aluno. A interface é responsiva, amigável e de fácil interação para estudantes.

1.3.2 ASR-API

Este módulo funciona como um intermediário entre o *frontend* e o modelo *Whisper* da *OpenAI*. Ele recebe os dados de áudio, em *base64*, enviados pelo usuário, envia ao *Whisper* para transcrição (áudio → texto) e retorna o texto transcrito para ser processado. Devido à grande complexidade computacional para processar com velocidade e assertividade os áudios recebidos, a API de transcrição fica hospedada no Google Cloud Platform.

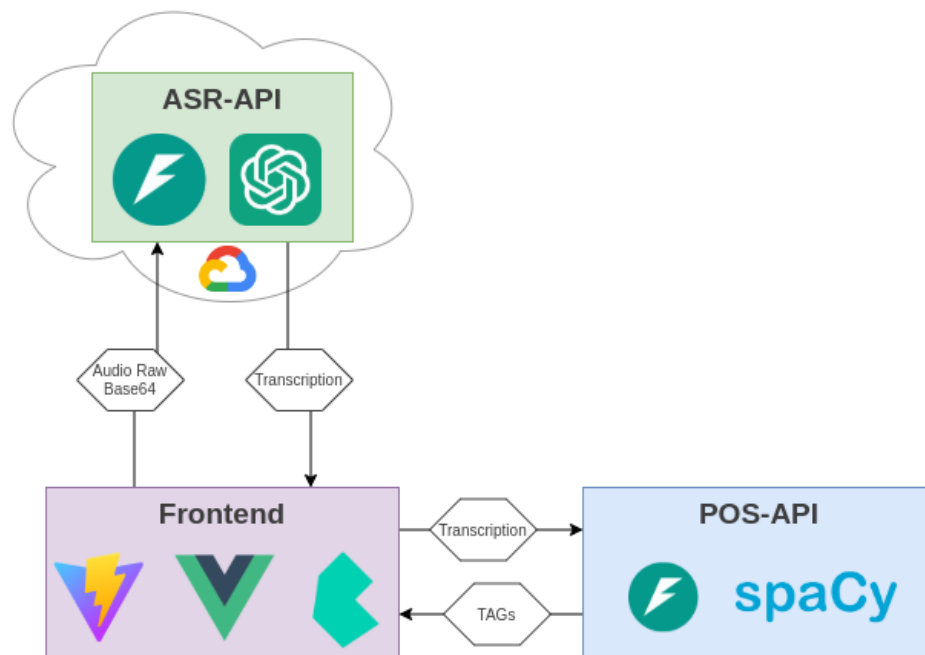


Figura 3 – Arquitetura do projeto

1.3.3 POS-API

Após a transcrição, o texto é enviado para o módulo de análise morfo-sintática, que utiliza o *Stanza* com modelo treinado para o idioma português. A POS-API realiza a etiquetagem das palavras (*part-of-speech tagging*), identificando a classe gramatical de cada termo da frase. O resultado é então devolvido ao *frontend* para exibição ao usuário.

1.4 Recursos e ferramentas utilizados

- **Whisper (OpenAI):** Modelo de reconhecimento automático de fala (ASR). Converte áudio em texto com alta precisão com suporte para o português e é ideal para tarefas de transcrição, legendagem e acessibilidade.
- **Stanza:** Uma biblioteca de Python desenvolvida pela Universidade de Stanford para processamento de linguagem natural (NLP). Ela oferece ferramentas como tokenização, lematização, análise morfo-sintática, análise sintática e reconhecimento de entidades nomeadas, funcionando em vários idiomas.
- **FastAPI:** Framework moderno para construção de APIs web em Python, com foco em alta performance e suporte nativo a validação de dados, documentação automática e integração com ferramentas de machine learning.
- **Vue.js:** Framework JavaScript progressivo e reativo para desenvolvimento de interfaces ricas e dinâmicas. Fácil de integrar e escalar, possui ótimo suporte à componentização.

- Vite: Ferramenta de *build* e servidor de desenvolvimento extremamente rápida. Utiliza ES Modules para melhorar o tempo de atualização durante o desenvolvimento e Rollup para builds finais otimizadas.
- Bulma: Framework CSS leve e moderno, baseado em Flexbox. Permite construir interfaces responsivas de forma simples e elegante, com uma sintaxe intuitiva e limpa.

1.5 Corpus Escolhidos

Para demonstrar a qualidade do *Whisper* e do analisador morfológico do *Stanza* o grupo selecionou dois corpus para analisar.

- Common Voice (ARDILA et al., 2020): conjunto de dados fornecido pela Mozilla composto por gravações de voz e suas respectivas transcrições, coletadas de voluntários em várias línguas, no nosso caso usaremos apenas a língua portuguesa.
- Porttinari (PARDO et al., 2021): O corpus Porttinari é um conjunto de dados brasileiro público composto por textos jornalísticos em português, que estão etiquetados com categorias morfossintáticas para facilitar a análise linguística.

1.6 Testes e Resultados

Fez-se testes para averiguar o funcionamento das ferramentas escolhidas para a parte de processamento de linguagem natural do GramatiQuiz.

1.6.1 Whisper

O modelo de transcrição escolhido para ser utilizado no projeto foi o *Whisper* da *OpenAI* (RADFORD et al., 2022). A variante testada em um ambiente virtual do Google Colaboratory foi o *whisper-tiny* devido a mudanças no projeto: inicialmente, o objetivo era o desenvolvimento de um software embarcado, por isso o emprego de um modelo menor. A métrica escolhida foi o *BLEU* score, no qual o modelo obteve uma pontuação de 0,3. Já o modelo maior (*whisper large-v3*, o qual será utilizado no projeto final), testado em uma amostra menor do dataset (500 instâncias) devido a limitações de *GPU*, obteve um *BLEU* score de 0,5, bem superior, podendo ser mais alto ainda caso avaliado em todo o corpus (aproximadamente 21 mil instâncias). Este modelo, quando testado anteriormente em seu lançamento, obteve taxa de 5.9% de erro. (RADFORD et al., 2022)

1.6.2 Stanza

O Stanza, pacote feito pela universidade de Stanford para PLN (QI et al., 2020), foi testado utilizando o Porttinari-base, um treebank multigênero feito pelo NILC ICMC USP (foram

utilizados os primeiros 500 registros por limitações do ambiente de teste.). Em ambos, teve uma performance bem aceitável, sendo que no último teve 92% de acurácia.

2 MODELO SIMBÓLICO

Inicialmente, explorou-se uma metodologia simbólica para a tarefa de predição da série escolar dos alunos a partir de seu desempenho em exercícios de etiquetagem morfofssintática. Essa abordagem fundamenta-se em regras explícitas derivadas de padrões observados nos dados, e tem como objetivo investigar se é possível capturar relações interpretáveis entre o comportamento dos alunos e sua respectiva série escolar.

2.1 Dataset e pré-processamento

O conjunto de dados foi extraído a partir de interações dos alunos com a plataforma *GramatiQuiz*, tendo sido pré-processado para que cada linha representa uma sessão de interação de um aluno com a plataforma de etiquetagem, contendo a sequência de respostas e a série escolar correspondente. Por não existir treinamento do modelo simbólico, não é necessária a divisão em conjuntos de treinamento e teste, uma vez que as regras são criadas a partir dos dados em si e podem ser validadas em todo o *dataset*.

2.2 Detalhes da modelagem

A análise simbólica partiu da observação do número médio de tentativas necessárias para que os alunos acertassem as etiquetas gramaticais propostas durante uma sessão. Para cada etiqueta — como substantivo, verbo, adjetivo, entre outras — computou-se, por série escolar, a média de tentativas realizadas antes do acerto. Por exemplo, se um aluno precisou realizar três interações até acertar a classificação de um substantivo, registrou-se esse valor como a quantidade de tentativas para aquela instância.

Com base nessa extração, foi possível calcular o número médio de tentativas por etiqueta e por série escolar. Essa análise revelou dois comportamentos distintos:

- Para etiquetas consideradas fáceis, observou-se uma tendência de queda no número médio de tentativas à medida que a série aumenta, sugerindo progresso no domínio daquelas categorias gramaticais.
- Para etiquetas mais difíceis, o número médio de tentativas permaneceu relativamente constante entre as séries, indicando uma dificuldade persistente, mesmo entre alunos de séries mais avançadas. Essa estabilidade pode refletir a complexidade intrínseca da etiqueta ou a ocorrência de respostas aleatórias (chutes) por parte dos alunos.

A figura 4 mostra alguns gráficos gerados a partir desses dados para as etiquetas com maior correlação negativa entre número de tentativas e a série do aluno. A figura 5 mostra alguns gráficos onde a correlação não foi tão forte. Uma visualização completa de todas as etiquetas relevantes utilizadas na geração das regras simbólicas é detalhada no Apêndice A.




Figura 4 – Alguns exemplos de etiquetas com alta correlação negativa entre seu número médio de tentativas e a série do aluno. Nota-se que, nesses casos, o número de tentativas diminui de acordo com a série do aluno, indicando maior domínio da gramática dessas entidades ao longo do aprendizado escolar.

2.2.1 Construção das Regras Simbólicas

Com os padrões identificados, é possível formular regras explícitas para inferência da série escolar de um aluno com base no seu desempenho individual em cada etiqueta. O procedimento é descrito a seguir:

1. Seleção de etiquetas com correlação negativa entre o número médio de tentativas e a série (ou seja, etiquetas cujo desempenho melhora com o avanço escolar).
2. Para cada etiqueta selecionada, foi definido um intervalo de tentativas típico por série, com base na variabilidade observada no conjunto de dados.




Figura 5 – Alguns exemplos de etiquetas com baixa correlação negativa entre seu número médio de tentativas e a série do aluno. Note que, no caso da interjeição, o número de tentativas não diminui de acordo com a série, apresentando comportamento semelhante ao aleatório, indicando não aprendizado. Já no caso da conjunção coordenativa, nota-se uma diminuição mais ruidosa, podendo ser atribuída à dificuldade dessa etiqueta em específico, na qual os alunos demoram mais para entender e erros continuam comuns mesmo em séries mais avançadas.

3. Para um aluno desconhecido, seu número de tentativas por etiqueta é comparado com os intervalos definidos. A série mais compatível com os valores observados é registrada como uma predição para aquela etiqueta.
4. Após a análise de todas as etiquetas relevantes, a série mais frequentemente atribuída entre elas é considerada a predição final da série escolar do aluno.

Mais especificamente, as regras criadas podem ser explicitadas da seguinte forma:

$$S(t, n) = \left\{ \begin{array}{ll} \{5, 6, 7\} & \text{se } t = \text{Preposição} \wedge n \geq 3 \\ \{8, 9\} & \text{se } t = \text{Preposição} \wedge 1 \leq n \leq 2 \\ \\ \{5, 6\} & \text{se } t = \text{Advérbio} \wedge n \geq 3 \\ \{7, 8\} & \text{se } t = \text{Advérbio} \wedge n = 2 \\ \{9\} & \text{se } t = \text{Advérbio} \wedge n = 1 \\ \\ \{5, 6, 7, 8\} & \text{se } t = \text{Artigo} \wedge n \geq 2 \\ \{9\} & \text{se } t = \text{Artigo} \wedge n = 1 \\ \\ \{5, 6\} & \text{se } t = \text{Substantivo} \wedge n \geq 2 \\ \{7, 8, 9\} & \text{se } t = \text{Substantivo} \wedge n = 1 \\ \\ \{5, 6\} & \text{se } t = \text{Pronome} \wedge n \geq 3 \\ \{7, 8, 9\} & \text{se } t = \text{Pronome} \wedge 1 \leq n \leq 2 \\ \\ \{5\} & \text{se } t = \text{Conjunção Subordinativa} \wedge n \geq 4 \\ \{6, 7, 8\} & \text{se } t = \text{Conjunção Subordinativa} \wedge n = 3 \\ \{9\} & \text{se } t = \text{Conjunção Subordinativa} \wedge 1 \leq n \leq 2 \\ \\ \{5, 6, 7\} & \text{se } t = \text{Preposição+Artigo} \wedge n \geq 3 \\ \{8, 9\} & \text{se } t = \text{Preposição+Artigo} \wedge 1 \leq n \leq 2 \\ \\ \{5, 6\} & \text{se } t = \text{Preposição+Pronome} \wedge n \geq 4 \\ \{7\} & \text{se } t = \text{Preposição+Pronome} \wedge n = 3 \\ \{8\} & \text{se } t = \text{Preposição+Pronome} \wedge n = 2 \\ \{9\} & \text{se } t = \text{Preposição+Pronome} \wedge n = 1 \\ \\ \{5\} & \text{se } t = \text{Verbo} \wedge n \geq 3 \\ \{6, 7, 8\} & \text{se } t = \text{Verbo} \wedge n = 2 \\ \{9\} & \text{se } t = \text{Verbo} \wedge n = 1 \\ \\ \emptyset & \text{caso contrário} \end{array} \right.$$

onde t é a etiqueta em questão e n é o número médio de tentativas para ela. A predição final é dada por

$$\text{Pred} = \text{moda} \left(\bigcup_i S(t_i, n_i) \right)$$

Essa abordagem, apesar de mais simples e interpretável, apresenta limitações, especialmente em relação à cobertura e precisão das regras. No entanto, ela oferece um caminho interessante para análises explicativas e como *baseline* simbólico para comparação com modelos estatísticos ou neurais mais complexos.

2.3 Resultados

Após a implementação das regras simbólicas descritas anteriormente, avaliamos o desempenho do modelo na tarefa de predição da série escolar com base nas interações dos alunos. A acurácia obtida foi de 23%, considerando como acerto a correspondência exata entre a série prevista e a série real do aluno. Embora esse resultado seja significativamente inferior ao da abordagem neural, ele ainda oferece uma perspectiva interessante sobre os padrões de erro dos estudantes e a viabilidade de inferências baseadas em regras interpretáveis.

A principal limitação observada foi a baixa capacidade das regras simbólicas em lidar com a variabilidade dos dados, especialmente no caso das etiquetas mais difíceis, cujo número de tentativas se manteve alto e constante entre as séries. Isso impossibilitou seu uso na construção das regras, resultando em menos informação a ser extraída do *dataset* e dificultando a distinção entre alunos de diferentes níveis escolares. Apesar disso, o modelo simbólico serviu como uma linha de base valiosa, permitindo identificar padrões explícitos de desempenho e fornecendo uma estrutura clara que pode ser útil em abordagens híbridas ou para fins educacionais.

3 MODELO NEURAL

Nesta etapa do projeto, empregou-se um modelo de linguagem neural baseado na arquitetura BERT com o objetivo de prever a série escolar (ano) de alunos com base em seus desempenhos em atividades de etiquetagem morfosintática. A escolha por essa abordagem se deve à robustez e versatilidade da arquitetura BERT, especialmente em tarefas de Processamento de Linguagem Natural (PLN) que exigem compreensão contextual e capacidade de generalização, assim como propensão ao ajuste-fino de seus parâmetros para tarefas mais específicas.

3.1 Detalhes da arquitetura

3.1.1 O BERT

O BERT (Bidirectional Encoder Representations from Transformers) é um modelo de linguagem desenvolvido pela equipe do Google em 2018 (DEVLIN et al., 2019). Baseado na arquitetura de transformers, o BERT se destaca por processar o texto de forma bidirecional, ou seja, levando em consideração o contexto tanto à esquerda quanto à direita de cada palavra. Essa característica permite ao modelo capturar nuances semânticas mais profundas do que abordagens anteriores unidirecionais. Um diferencial do BERT é seu treinamento em duas tarefas de pré-treinamento: Masked Language Modeling (MLM) e Next Sentence Prediction (NSP), o que o torna altamente eficaz para tarefas de finetuning supervisionado em diferentes aplicações de PLN, que é o caso deste projeto.

3.1.2 O BERTimbau

Para lidar com dados em língua portuguesa, optou-se por utilizar o BERTimbau, uma versão do BERT pré-treinada especificamente em português brasileiro (SOUZA; NOGUEIRA; LOTUFO, 2020). O BERTimbau foi treinado pela equipe da NeuralMind utilizando uma grande coleção de textos em português, e está disponível em dois tamanhos: base e large. Neste projeto, utilizamos o modelo bert-base-portuguese-cased, que fornece um bom equilíbrio entre desempenho e custo computacional. Por ser um modelo ajustado à morfologia e sintaxe do português, o BERTimbau se mostrou mais apropriado para a tarefa em questão do que modelos multilíngues.

A escolha do BERTimbau se baseia na própria arquitetura do BERT, que favorece o finetuning para tarefas específicas, como classificação de texto, análise de sentimentos ou, neste caso, a predição da série escolar. A combinação entre o pré-treinamento genérico e a capacidade de adaptação a tarefas downstream faz do BERT (e de suas variantes) uma das abordagens mais eficazes para problemas supervisionados em PLN.

3.2 O Conjunto de Dados

O dataset utilizado nesta etapa parte do mesmo conjunto de dados do modelo simbólico, porém com pré-processamento diferente. Ele também é composto por sessões de interação de estudantes com a plataforma de etiquetagem morfossintática desenvolvida neste projeto (*GramatiQuiz*), onde cada linha representa uma sessão de um aluno contendo uma sequência textual que resume suas ações na plataforma, incluindo acertos e erros em diferentes categorias gramaticais. Essas sequências foram formatadas como strings para viabilizar a entrada no modelo BERT, respeitando o formato de dados textuais requerido para tokenização e processamento posterior. As informações utilizadas em cada entrada do modelo incluem:

- A frase original sendo etiquetada;
- Se a tentativa foi completa ou se o estudante desistiu antes;
- A palavra com a qual o aluno está interagindo;
- A etiqueta correta da palavra em questão;
- A etiqueta que o aluno atribuiu à palavra em questão;
- Se essa interação constituiu um erro ou não;
- A ordem da interação dentro da sessão (se essa palavra foi a primeira a ser etiquetada ou a segunda, terceira, etc.).

Além das interações, cada entrada no dataset também inclui a série escolar do aluno, utilizada como rótulo para a tarefa de classificação.

3.2.1 Pré-processamento e Treinamento

O *pipeline* de preparação dos dados envolveu diversas etapas. Inicialmente, utilizou-se a biblioteca *pandas* para carregamento e pré-processamento do dataset bruto, como o agrupamento das entradas de acordo com o id da sessão e a formatação das features em strings para permitir a ingestão por parte do modelo de linguagem. Em seguida, aplicamos técnicas de validação cruzada utilizando o método *KFold* com $k=5$, implementado com a biblioteca *scikit-learn*, a fim de garantir uma avaliação mais robusta do modelo e mitigar o risco de *overfitting*.

Para o treinamento propriamente dito, utilizamos as bibliotecas *Transformers* e *Dataset* da *Huggingface*. A tokenização das sequências foi feita com o tokenizador correspondente ao *BERTimbau*, e o modelo foi instanciado para uma tarefa de classificação com múltiplas classes (uma para cada série escolar). O modelo foi então ajustado aos nossos dados via *finetuning*, com diferentes experimentações de hiperparâmetros e versões levemente distintas do dataset, assim como diferentes formas de divisão do conjunto de dados.

3.3 Resultados

Apesar das limitações de tamanho e diversidade do dataset, o uso de validação cruzada permitiu melhorar a capacidade de generalização do modelo. Após diversas execuções e ajustes, obtivemos uma acurácia máxima de 54%, um resultado modesto, mas representativo dado o caráter desafiador da tarefa e a natureza dos dados disponíveis. O desempenho sugere que a tarefa de predizer a série escolar a partir de interações linguísticas curtas é complexa, mas que há potencial de melhoria com a ampliação e diversificação do dataset ou emprego de outros modelos.

4 APÊNDICES

4.1 Análise das etiquetas na abordagem simbólica

Os gráficos abaixo foram gerados a partir dos dados obtidos da plataforma do *Gramati-Quiz*, e ilustram as correlações entre as etiquetas utilizadas na construção das regras simbólicas e a série dos alunos.

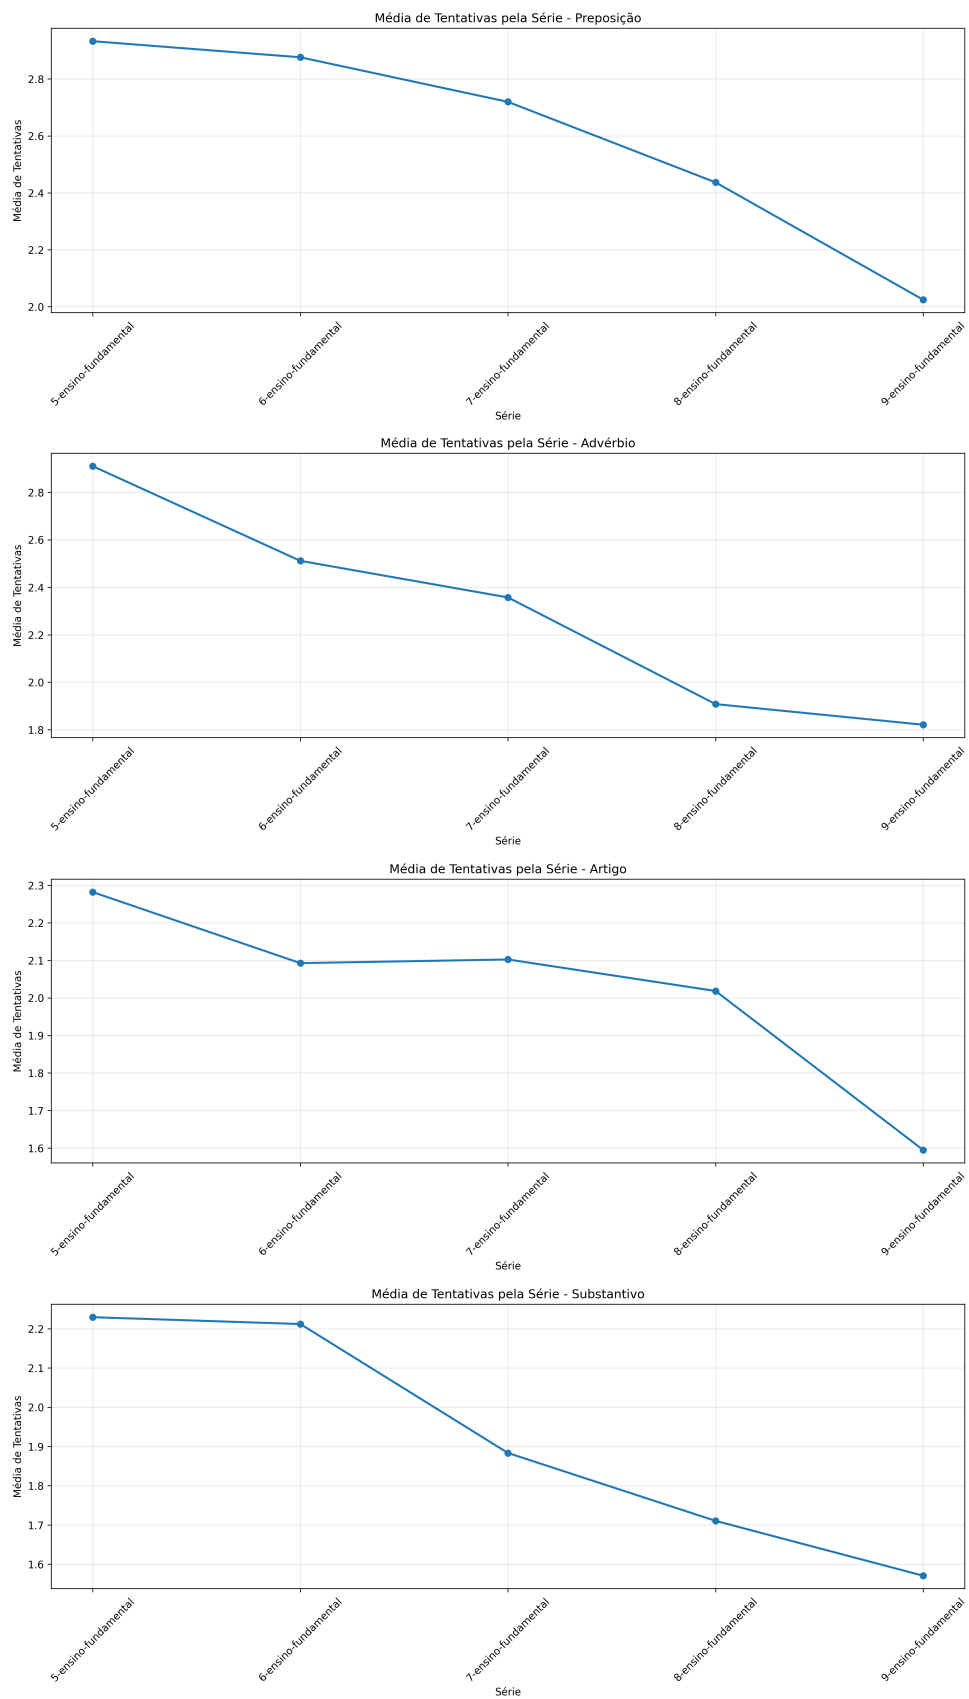


Figura 6

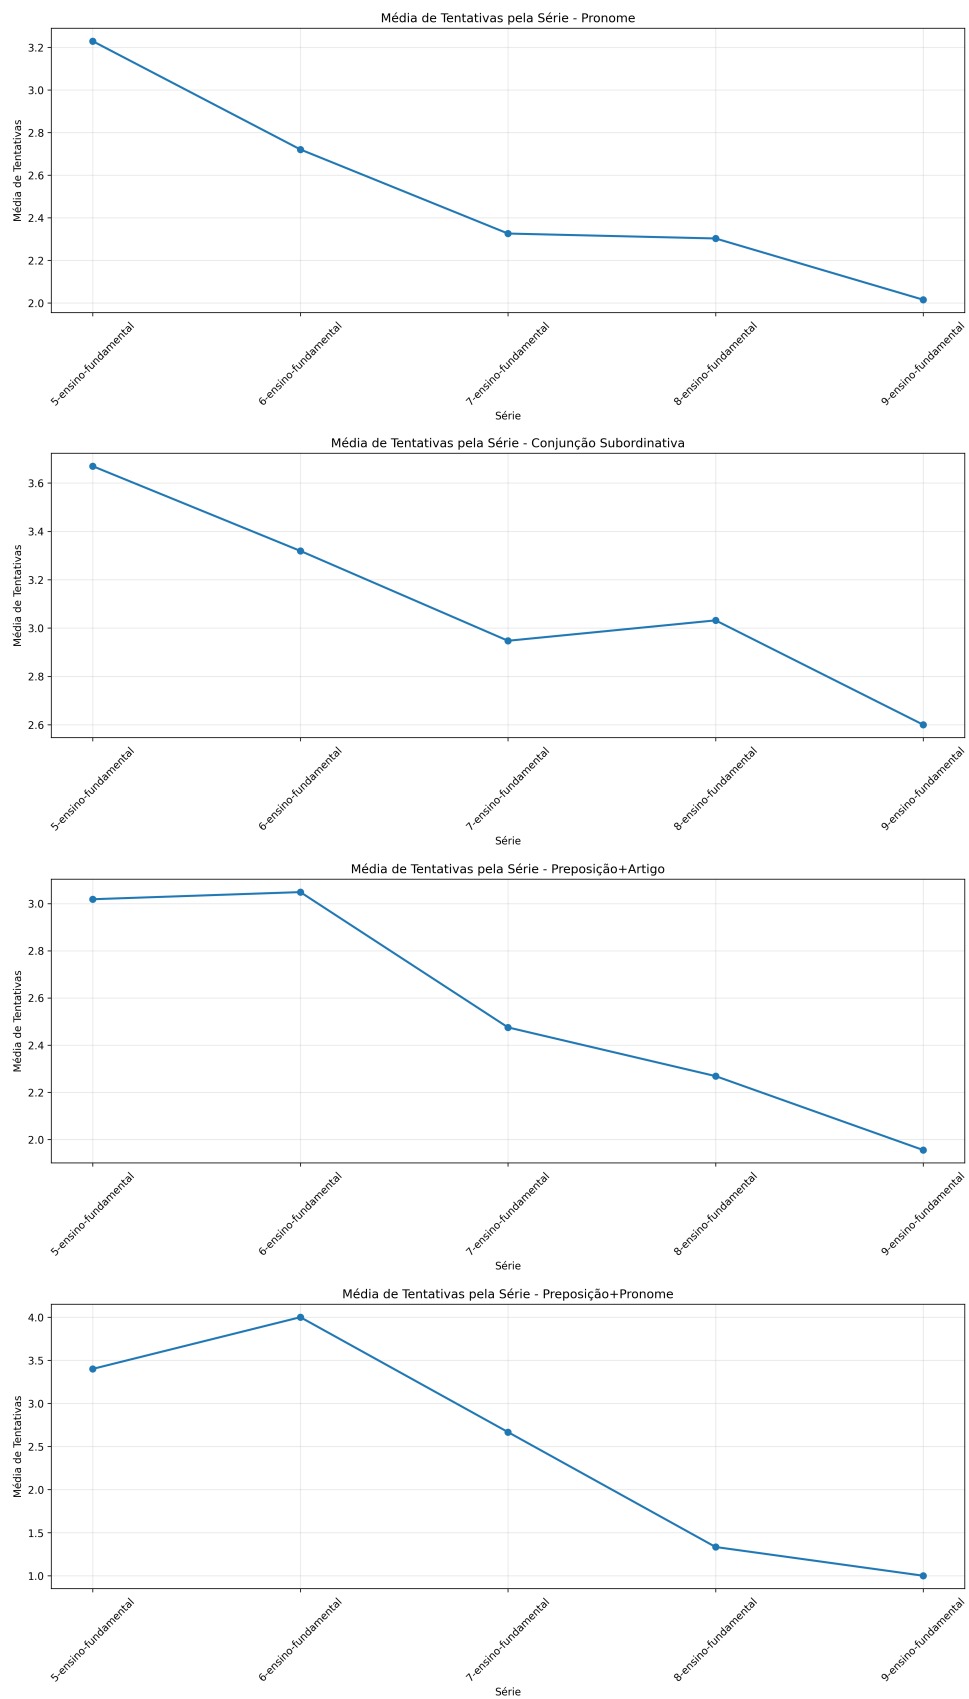


Figura 7

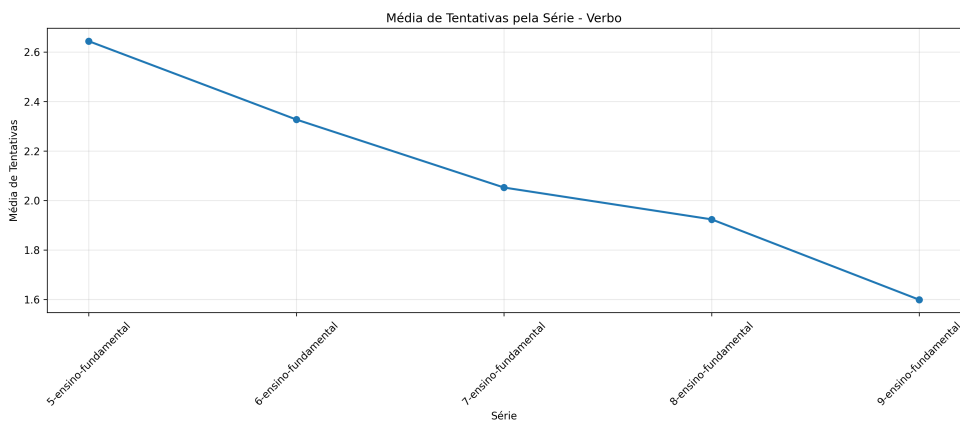


Figura 8

REFERÊNCIAS

- ARDILA, R. et al. *Common Voice: A Massively-Multilingual Speech Corpus*. 2020. Disponível em: <<https://arxiv.org/abs/1912.06670>>. Citado na página 6.
- DEVLIN, J. et al. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. 2019. Disponível em: <<https://arxiv.org/abs/1810.04805>>. Citado na página 13.
- PARDO, T. A. S. et al. *Porttinari - a Large Multi-genre Treebank for Brazilian Portuguese*. 2021. Disponível em: <<https://sites.google.com/icmc.usp.br/poetisa/porttinari-2-0>>. Citado 2 vezes nas páginas 3 e 6.
- QI, P. et al. *Stanza: A Python Natural Language Processing Toolkit for Many Human Languages*. 2020. Disponível em: <<https://arxiv.org/abs/2003.07082>>. Citado 2 vezes nas páginas 3 e 6.
- RADFORD, A. et al. *Robust Speech Recognition via Large-Scale Weak Supervision*. 2022. Disponível em: <<https://arxiv.org/abs/2212.04356>>. Citado 2 vezes nas páginas 3 e 6.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. Bertimbau: Pretrained bert models for brazilian portuguese. In: _____. [S.l.]: Springer, 2020. p. 403–417. ISBN 978-3-030-61376-1. Citado na página 13.